信息处理技术 作业3

From: 梁鑫宇 3160104494

题目:英文自动分词,要求能处理标点符号

思路分析:

1. 语言选择

根据上课时课件中给出的算法,分析使用指针可以完成任务且较为直观,故选择c语言来完成。

2. 思路分析

分词需要辨别英文单词与各种标点符号,其中包含属于单词结构的连接符,缩写词的'号等以及分隔单词的分隔符。

考虑英文输入标准要求分隔单词要有空格。又有可能段尾无空格直接换行,故考虑以空格和换行作为分隔单词的标准。

由于各种标点符号作用不同,且数量较多。若依次判断太过繁琐,反向考虑通过筛选读入只保留有意义的英文单词和连接符等,其他符号直接未读入存储数组。由是则只要合理地输出所保存的数组即可。

源代码:

```
#include <stdio.h>
#include <stdlib.h>
#define DEFAULTSIZE 100
void show(char* words,int size);
char* morespace(char* words,int* maxsize);
int main() {
   //通过malloc函数获取一个指针形式的字符数组
   char* words = (char*)malloc(sizeof(char)*DEFAULTSIZE);
   int size = 0;//记录字符数组目前存储了多少字符
   int maxsize = DEFAULTSIZE;//记录目前字符数组的大小
   char ch;
   //当用户没有使用EOF结束输入时进入如下循环
   while(scanf("%c",&ch) != -1){
      //由于任务目标是英文分词,此处只将英文字符,可能出现的连接符以及空格和换行读入字符数组
      if(ch == ' ' || (ch>=65&&ch<=122) || ch == '-' || ch == '\'' || ch == '\n'){
          words[size] = ch;
          ++size;
      }
      //每读入一个字符,判断一下数组是否满了。如果已经满了,调用morespace函数
```

```
if(size == maxsize){
          words = morespace(words,&maxsize);
   }
   show(words, size);//输出结果
   free(words);//释放内存
   return 0;
}
//输出分词结果,每个单词一行
void show(char* words,int size){
   int new_line = 0; //记录是否已经换过行,可处理掉输入中多余的空行
   for(int i = 0;i<size-1;++i){</pre>
       if(words[i] == ' ' || words[i] == '\n'){
          //如果此前输出字符还没有换过行,那么输出换行符分隔此单词
          if(new line == 0){
             printf("\n");
             new_line = 1;//并将此值标记为1
          }
      }
      //若不是分隔符空格或换行,则为单词的组成部分,正常输出
          printf("%c",words[i]);
          new_line = 0;//此时为一个单词的字符逐个输出,标记换行次数为0
      }
   }
}
//获取更大空间的字符数组
char* morespace(char* words,int* maxsize){
   //通过malloc函数获得一个更大的字符数组
   char* new_words = (char*)malloc(sizeof(char)*(*maxsize+DEFAULTSIZE));
   //利用指针操作修改maxsize的值
   *maxsize = *maxsize + DEFAULTSIZE;
   //将原来字符数组里的字符逐个赋到新的数组中
   for(int i = 0;i<*maxsize;++i){</pre>
      new_words[i] = words[i];
   }
   //返回新的字符数组
   return new_words;
}
```

测试样例

测试文本: 十九大报告英文版节选

包含连字符的单词

pursuing

